SNU AICEO 5 · PROJECT RESULT

Maris 온디바이스 AI 음성 비서

인터넷 연결 없이, 셋톱박스 하나로 음성 질의응답 / 문제해결 하는 AI 프로젝트.

DEVICE	PERIOD	STATUS
Realtek RTD1635 SoC	2026.08 – 2026.10	Real demo ready


인터넷
IPTV / OTT / 웹서비스
Wi-Fi
집안 무선 연결
스마트홈 클라우드
기기 관리 / AI 서비스
홈 CCTV
실시간 모니터링
움직임 알림
스마트 조명
켜기/끄기
밝기·색상 제어
냉난방/에어컨
온도 제어
에너지 관리
스마트 도어락
원격 잠금/해제
방문자 알림
IPTV
TV 다시보기
영화
OTT
앱
스마트홈
AI 비서
LIVE
NETFLIX
YouTube
Disney+
TVING
wavve
추천 콘텐츠
IPTV 셋탑 (홈 허브)
영상 + 인터넷 + 스마트홈 제어의 중심
스마트폰 연동
집 안팎에서 제어
알림 수신
스마트홈 기기
스마트 스피커
스마트 디스플레이
로봇청소기
청소 예약
상태 확인
가전 연동
세탁기, 냉장고 동
상태 확인 / 원격 제어
1. 풍부한 콘텐츠
IPTV, OTT, 유튜브 동
다양한 영상 서비스
2. 스마트홈 허브
집안의 다양한 IoT 기기를
하나로 연결하고 제어
3. AI 비서
음성으로 콘텐츠 검색,
스마트홈 제어, 생활 정보 제공
"거실 조명 켜줘"
"에어컨 24도로 해줘"
"오늘 날씨 알려줘"
"넷플릭스 틀어줘"
4. 원격 관리
외부에서도 스마트폰으로
집 안 기기 상태 확인 및 제어
우리집
조명
켜짐
에어컨
24℃
도어락
잠김
로봇청소기
청소중

“IPTV knows what you watched last night. AI knows what you'll want to watch tonight.”

ONE-LINE SUMMARY

“인터넷이 끊겨도, 셋톱박스가 알아서 답한다”

사용자가 “Hey Maris”라고 부르고 문제를 물으면, 인터넷 연결 없이 기기 안에서 검색·판단·답변 생성·음성 출력까지 전부 처리.

100%

오프라인 동작 — 핵심 Q&A 루프에 클라우드 서버 의존 없음

5개

지원 언어 (한/영/스페인어/독일어 등, OS 로케일 자동 감지)

₩0

쿼리당 클라우드 추론 비용 — 전량 온디바이스 처리

DEVELOPMENT TIMELINE

3개월, 5단계로 완성

텍스트 파이프라인부터 NPU 가속, 신규 기능까지 순차적으로 구현.

08월

베이스 파이프라인

웨이크워드→STT→검색→LLM→TTS 구현

08-09월

UI·다국어 확장

카드뉴스형 UI 도입, Gemma3·임베딩 전환, 5개 언어 지원

9월

NPU 온디바이스 전환

Realtek VIP9000 NPU로 LLM 추론 이관, 벤더 협업

10월 초

성능 목표 달성

목표10 token/s

10월 말

셀프헬프 기능

5개 문제해결 시나리오 + 전용 UI

DEVELOPMENT STAGES · 1/2

무엇부터 시작해서 어디까지 할까 (1/2)

클라우드 LLM이 아니라, 처음부터 "이 기기 안에서 전부 처리한다"를 목표.

1. **텍스트 파이프라인 (8월)**
   웨이크워드 → 음성인식 → 검색 → LLM → 음성합성, 5단계 구현.
2. **카드 UI 도입 (8월)**
   텍스트 로그 화면에서, 지금의 카드뉴스형 HUD로 전환. 답변에 맞춰 화면이 함께 움직이는 형태.
3. **검색 엔진을 AI 임베딩 기반으로 (9월)**
   키워드 매칭에서 의미 기반 검색(AI 임베딩 모델)으로 전환 — "표현이 달라도 같은 질문"을 인식하도록.
4. **다국어 확장 (8~9월)**
   기기 설정 언어에 맞춰 응답 언어·음성·화면 텍스트를 자동 전환. 5개 언어 지원.
5. **NPU 온디바이스 전환 시작 (10월)** NPU
   범용 런타임으로 먼저 동작을 검증한 뒤, LLM 추론을 전용 NPU(Realtek VIP9000)로 이관.

DEVELOPMENT STAGES · 2/2

무엇부터 시작해서 어디까지 할까 (2/2)

NPU 전환 이후는 "속도"와 "완성도" 향상

6 **모델 변환 및 NPU 이식** NPU

AI 모델(Gemma3 1B)을 벤더 전용 툴체인으로 양자화·변환해 NPU 전용 포맷으로 만들고, 기기에서 직접 구동.

7 **벤더 협업** NPU

벤더(Realtek)와 데이터 기반으로 목표 속도 확보예정.

8 **응답 품질 안정화 (9~10월)**

답변이 지나치게 길어지거나 반복되는 문제를 걸러내는 필터 도입등으로 완성도 향상 예정.

9 **셀프헬프 기능 추가 (10월 중순)**

가장 빈번한 고객 문의 5종을 신규 시나리오로 추가하고, 전용 카드 UI 적용. 화면 전환 완성도 향상 예정.

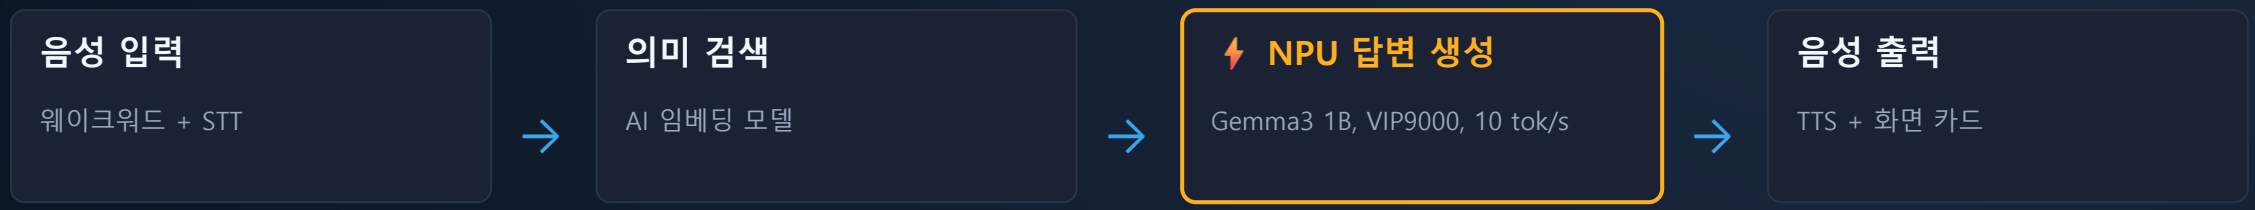
10 **AI CEO 데모**

Maris 연관 디바이스 데모.

SYSTEM ARCHITECTURE

전체 구조

음성 인식부터 답변 재생까지 5단계 파이프라인.



EDGE INTELLIGENCE

Standalone AI Virtual Support Bot

Edge Intelligence:
The Standalone AI Virtual Support Bot

Core Capability

A smart, local virtual support bot designed to deliver AI-based recommendations by integrating a voice assistant with a comprehensive product user guide.

Advanced Local AI

Proves that complex AI architectures—including Transformers, Large Language Models (LLMs), and Retrieval-Augmented Generation (RAG)—can run efficiently and effectively directly on edge devices.

100% Standalone Solution

Operates an entire pipeline of AI models solely on the edge, providing full functionality with absolutely no cloud dependency or internet connectivity required.

Core Capability

음성비서와 제품 사용설명서를 결합해, AI 기반 추천·안내를 로컬에서 제공

Advanced Local AI

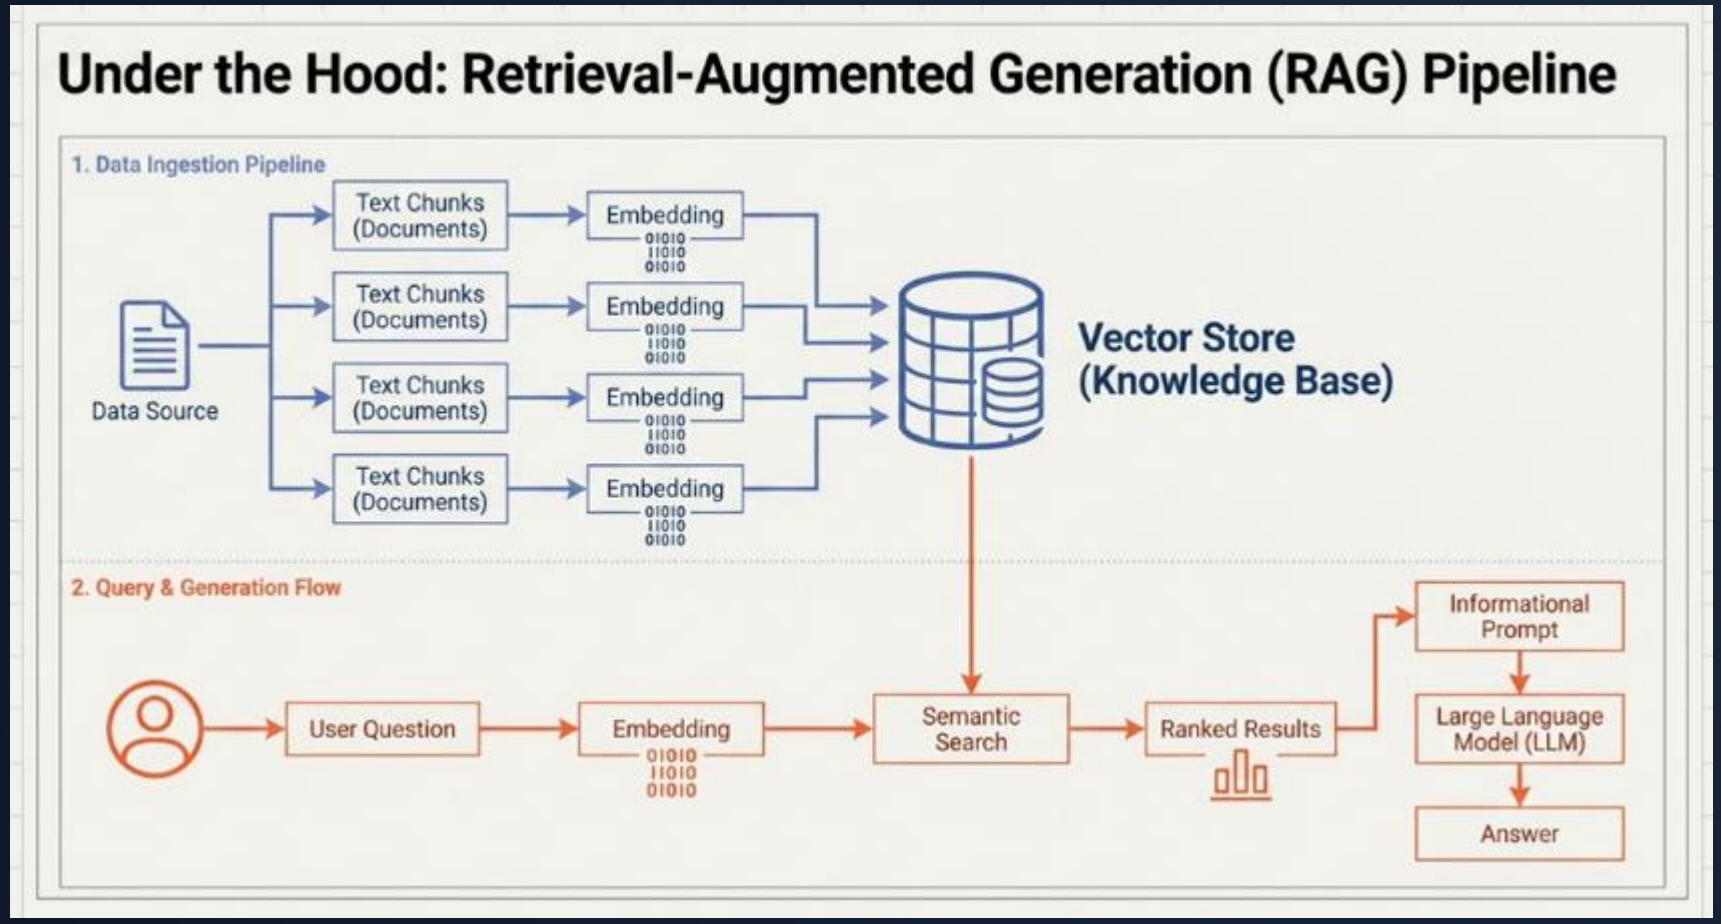
Transformer, LLM, RAG 같은 복잡한 AI 구조가 엣지 디바이스에서 효율적으로 동작함을 실증

100% Standalone

전체 AI 파이프라인이 엣지에서만 동작 — 클라우드 의존·인터넷 연결 불필요

UNDER THE HOOD

RAG Pipeline



Data Ingestion Pipeline

문서를 텍스트 청크로 분할 → 임베딩 → 벡터 저장소(지식베이스)에 축적

Query & Generation Flow

질문 임베딩 → 의미 검색 → 랭킹된 결과로 프롬프트 구성 → NPU LLM이 최종 답변 생성

FEATURE HIGHLIGHT

셀프헬프 — 5대 문제해결 시나리오

가장 빈번한 고객 문의 5종을 음성 + 4단계 시각 카드로 안내합니다.



인터넷 연결



리모컨



소리 안 남



화면 멈춤



SW 업데이트

NEXT VISION

Function Calling까지 가려면 필요한 것

단순히 "기능을 켠다"의 문제가 아니라, 소형 온디바이스 모델이 안정적으로 올바른 액션을 호출하도록 만드는 학습·안전장치가 함께 필요.

🧠 지식 증류 (Distillation)

대형 모델(예: Gemma3 27B급)로 고품질 Function-Call 예시를 생성해, 이를 1B급 온디바이스 모델이 따라 하도록 학습 — 크기는 유지하면서 tool-use 능력만 이전.

🎛️ LoRA 파인튜닝

모델 전체를 재학습하지 않고 작은 어댑터만 학습·교체 — NPU 변환 파이프라인 전체를 반복하지 않고도 빠르게 실험 가능.

🛠️ 액션 스키마 설계

"라우터 재시작", "채널 전환" 같은 실제 기기 API를 LLM이 호출 가능한 함수 형태(파라미터 포함)로 정의.

🛡️ 실행 안전장치

허용된 함수만 호출 가능하도록 화이트리스트 적용, 실행 전 파라미터 검증, 필요 시 사용자 확인 단계 추가.

📊 Function-Call 평가 체계

"답변이 자연스러운가"가 아니라 "올바른 함수를 올바른 인자로 호출했는가"를 측정하는 별도 평가 기준 필요.

⚡ NPU 재변환 & 재검증

파인튜닝된 모델도 동일한 NPU 변환·양자화 과정을 다시 거쳐야 하며, 구조화된 출력 특성에 맞춰 속도를 재벤치마크.

AI CEO

3종 데모 예정

Maris 외 2개 관련 디바이스 데모까지 함께 준비해, 서로 다른 아키텍처를 비교 시연 예정.

RTD1635 · ON-DEVICE LLM

Maris 셀프헬프

완전 온디바이스 RAG + NPU LLM 음성 비서

BROADCOM BCM74116

AI 셋톱박스 9기능

Guardian, Security, Call Center 등 9개 AI 기능 통합 데모

REALTEK DONGLE · NO LLM

하이브리드 검색

LLM 없이 임베딩+BM25F로 100% 예측 가능한 답변 제공

MARUSYS · IPTV SET-TOP BOX AGENT AI

Maris
On-Device Agentic AI

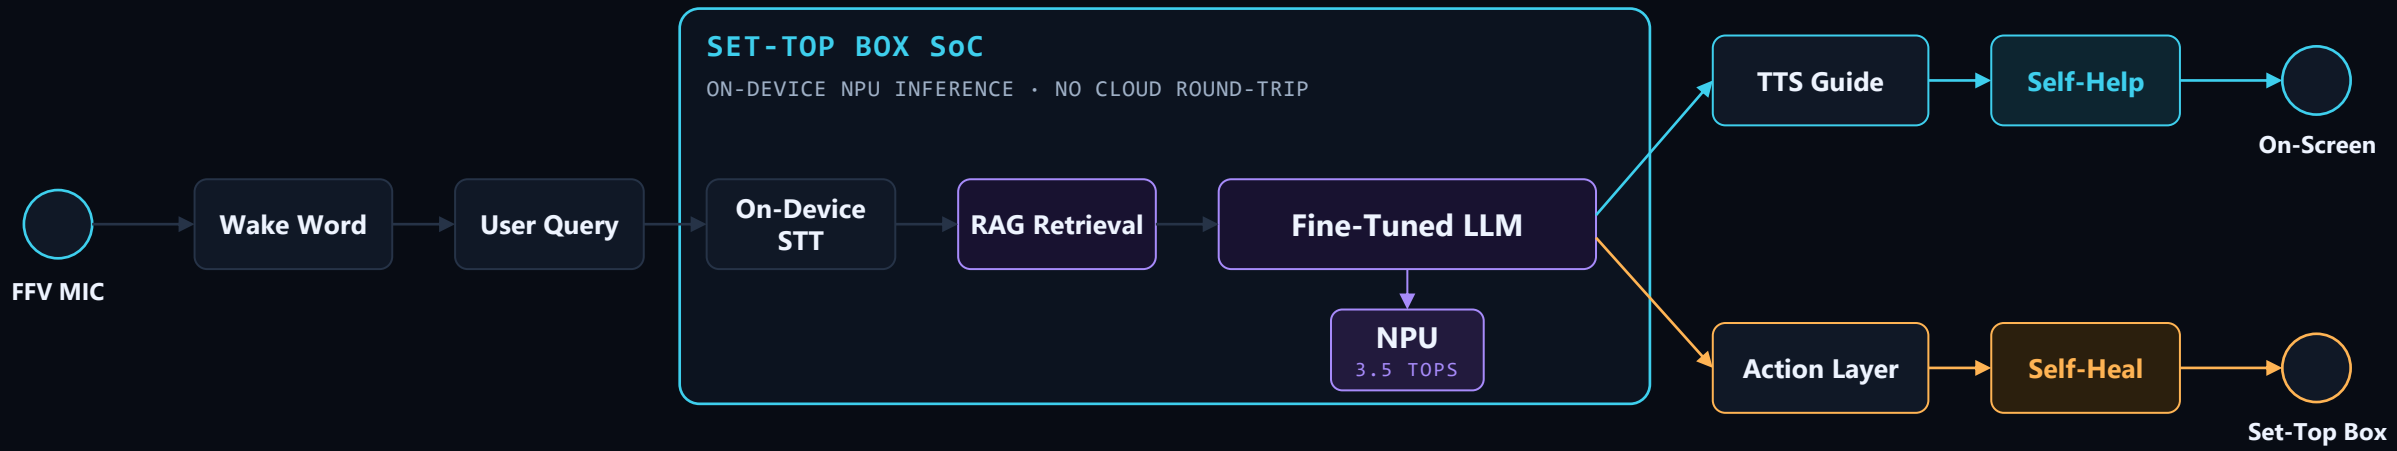
Voice support for the set-top box — self-help and self-healing.

01	Wake word detection
02	On-device recognition
03	Retrieval over a local corpus
04	Fine-tuned generation
05	NPU inference
06	Spoken guidance
07	Performed repair

INFERENCE	MODEL	LANGUAGES	CLOUD CALLS
Realtek VIP9000 NPU	**Gemma 3 1B, fine-tuned**	**ko · en · es · de · fr**	**0**

The whole pipeline, on one chip.

Every block below runs on the set-top box. Nothing on this path leaves it.



Self-Help — the box explains how to fix to the customer

Self-Heal — the box performs the fix itself

HOW TO READ IT

One front half, two different endings.

Every request shares the same path up to the model. What changes is what happens after it.

Self-Help — the box explains

The retrieved answer is spoken and drawn at the same time, stepping forward sentence by sentence.

COVERS	**6 troubleshooting topics** — remote, sound, freezing, internet, update, performance
SURFACE	A WebView HUD composited over the live TV UI

Self-Heal — the box acts

Where the fault is something software can reach, Maris does not read out instructions. It asks, then repairs.

REPAIRS	Mute cleared and volume restored; device restarted
GATE	A spoken yes/no, resolved from the interim result

01 · ALWAYS LISTENING

Wake Word

Sensory TrulyHandsfree, running continuously in a foreground service. It is the only thing awake until it hears the phrase — and it never sends audio anywhere.

ENGINE	Sensory TrulyHandsfree — PhraseSpot + VAD task
MODELS	`tpl-spot-vad-3.13.0.snsr` template with a custom phrase model
PHRASE	“Hey Maris” / “헤이 마리스”
BACKOFF	250 ms after a detection before the engine can trigger again, so one phrase fires once.

7 of 21

Sensory operating point, raised to catch quiet speech.

IN THE PIPELINE

Nothing leaves the device

Detection is local; no audio is buffered off-box while idle.

02 · RECOGNITION

On-Device STT

Android's own recogniser, pinned to its on-device path. On Android 13 and up that is a recogniser with no network path at all, not a cloud recogniser with a flag set.

API 33+	`createOnDeviceSpeechRecognizer()` — fully air-gapped
HANDOFF	The wake-word session passes its open stream on, so the microphone is never opened twice
PARTIAL RESULTS	Acted on, not just logged. A confirmation resolves on the first conclusive interim result — the recogniser otherwise holds a confident hypothesis for up to 8 s waiting for silence.
LANGUAGES	ko · en · es · de · fr, switched per-app rather than system-wide

0.75 seconds

To act on a spoken yes or no, down from 2–7 s.

IN THE PIPELINE

Alternatives in tree

Vosk and a Gemma STT backend are selectable; Google on-device is the default.

03 · GROUNDING

RAG Retrieval

RAG — retrieval-augmented generation — does not rely on what the model remembers. The answer is looked up first and the model is asked to relay it; if nothing matches well enough, the model is not called at all.

HOW IT RUNS	Embed the question → compare it against the card vectors → put the closest card into the context the LLM is handed.
WHAT IS EMBEDDED	One vector per FAQ card, built from its ~5 question paraphrases and the full answer text together — not the raw document.
EMBEDDER	**EmbeddingGemma-300M**, seq-256 mixed-precision TFLite — 170.8 MiB, CPU, memory-mapped. 768 dimensions, L2-normalised.
QUERY SIDE	Card vectors are precomputed offline and ship in the APK; per turn only the question itself is embedded, as a RETRIEVAL_QUERY.
MATCH	Cosine similarity, top-1, accept threshold 0.40. Below it the turn returns Not Found and the LLM is never called.

0.40 threshold

IN THE PIPELINE

Corpus — what it can answer

The written set of answers Maris draws from — product cards plus 6 self-help cards, authored ahead of time, 19 per language.

This is the hallucination answer

The model relays a curated answer; it does not compose one from its own knowledge.

04 · GENERATION

Fine-Tuned LLM

Gemma 3 1B, fine-tuned for an unusual job: reproduce the retrieved answer word for word. Instruction-tuned models paraphrase by default, and paraphrase is what loses the names and numbers — so here, paraphrasing is the failure.

BASE	`google/gemma-3-1b-it` with LoRA, merged to fp16 — the export shape Realtek's NPU conversion is already validated against
MEMORY	1,270.8 MiB on disk after int4 quantisation; **1.44 GB** measured while running — about 20% of the board's 7.27 GiB.
TRAINING DATA	The app's own FAQ corpus, rendered through the exact production prompt template, so training matches what the device sends.
SYSTEM PROMPT	All five languages share one terse framing, held to ~44 tokens each so the retrieved context and the question keep their share of the prefill budget.

1B parameters

Gemma 3, LoRA fine-tuned

IN THE PIPELINE

Why verbatim

Product names and figures have to survive intact — a paraphrased instruction is a wrong instruction.

A 256-token prefill budget

System prompt, retrieved context and question all share it, which is what sets the sizes above.

05 · SILICON

VIP9000 NPU

The model does not run on the CPU. Its weights are DMA'd into an NPU arena as they sit on disk — which is also why measuring its memory needs a different method than every other process on the box.

HARDWARE	Realtek **VIP9000** NPU, AcuityLLM Runtime, driven as a persistent CLI subprocess
QUANTISATION	`Afp16Wpgqi4` — fp16 activations, per-group int4 weights
DISK VS MEMORY	The model file is 1,270.8 MiB; the arena is **3.1% larger**. Nothing is dequantised on load, and the KV cache is pre-allocated inside that same arena.
TUNING	DDR bandwidth limits applied at conversion time: **TTFT −44%**, decode **+8%**

1,310.6 MiB

The NPU weight arena, measured — not estimated.

IN THE PIPELINE

Why the usual tools read zero

Those pages report Rss/Pss 0 — the NPU writes into them, the CPU never faults them in.

06 · GUIDANCE PATH

Self-Help

The retrieved answer is spoken and drawn at the same time — the on-screen guide steps forward sentence by sentence as the voice reaches them.

VOICE	Android on-device TTS. A cloud voice is optional and used only when a key and network are both present, with automatic fallback to native.
SYNC	Sentences are queued individually, so each one's start event advances the matching step on screen
SURFACE	A WebView HUD composited over the live TV UI — the idle architecture diagram is this same layer

6 cards

Troubleshooting topics the box can walk a customer through.

IN THE PIPELINE

Topics covered

Remote not responding · no sound · video freezing · unstable internet · software update · slow performance.

07 · REPAIR PATH

Self-Healing

Where the fault is something software can reach, Maris does not read out instructions. Once the customer says yes, it invokes a repair — a registered action on the device, not free-form output.

TOOL LAYER	Each repair is a named action with a typed effect and a confirmation gate — the shape function calling and MCP give a model's tools.
WHAT ROUTES IT	The retrieval match selects the action, so the path from a known fault to its repair stays deterministic.
NO SOUND	Real mute detection and repair — stream mute mirrored to DSP-level mute, volume raised if it sits at zero
RESTART	A real reboot, with a marker so the box greets the customer differently afterwards
CONFIRMATION	Spoken yes/no. If the window expires with nothing recognised, Maris says so and reopens it **once**.

2 live repairs

Mute cleared and device restarted — not simulated.

IN THE PIPELINE

Privilege

Platform-signed system app; reboot and secure-settings rights come from the privapp allowlist.

What to demo

Mute the box first, then ask “there is no sound” — Maris clears it live.

THE PLATFORM

What it runs on.

Every stage above runs inside this one box. The figures below were read off the demo unit, not copied from a datasheet.

SILICON	
CPU	4 cores — 1× Cortex-A76 at 1.9 GHz and 3× Cortex-A55 at 1.7 GHz, ARMv8.2-A
GPU	ARM Mali-G310, OpenGL ES 3.2
NPU	Realtek **VIP9000 — 3.5 TOPS**, via /dev/vipcore, driven by the AcuityLLM runtime

SYSTEM	
MEMORY	**8 GB LPDDR4** — 7.27 GiB usable
STORAGE	32 GB eMMC
OS	Android 16 (API 36), Linux kernel 6.12.38
THE APP	Platform-signed system app in /system/priv-app, so it can reboot and change secure settings

MEASURED ON THE DEMO UNIT

What it costs to run.

Every figure here was measured on the demo unit in the booth, not quoted from a datasheet.

SPEED

8.57 tok/s

Decode throughput, up from ~5–6 before the DDR patch

SPEED

390 ms

Time to first token, down from ~689 ms

MEMORY

1.44 GB

LLM memory — NPU weight arena plus runtime

MEMORY

0.76 GB

App memory, including the 170.8 MiB embedding model

MEMORY

7.27 GiB

Usable system memory on an 8 GB LPDDR4 board

SCOPE

5 languages

Each with its own corpus and precomputed embeddings

SCOPE

19 entries

FAQ size per language

SCOPE

0 cloud calls

On wake word, recognition, retrieval and generation

No part of this needs a network to answer you.

Wake word, recognition, retrieval, generation and the repair itself all run on the set-top box. Unplug the internet and Maris Agent still works. And the path ends in a repair, not an explanation — the box diagnoses the fault and performs the fix once the customer agrees.

MARUSYS · ANDROID IPTV SET-TOP BOX

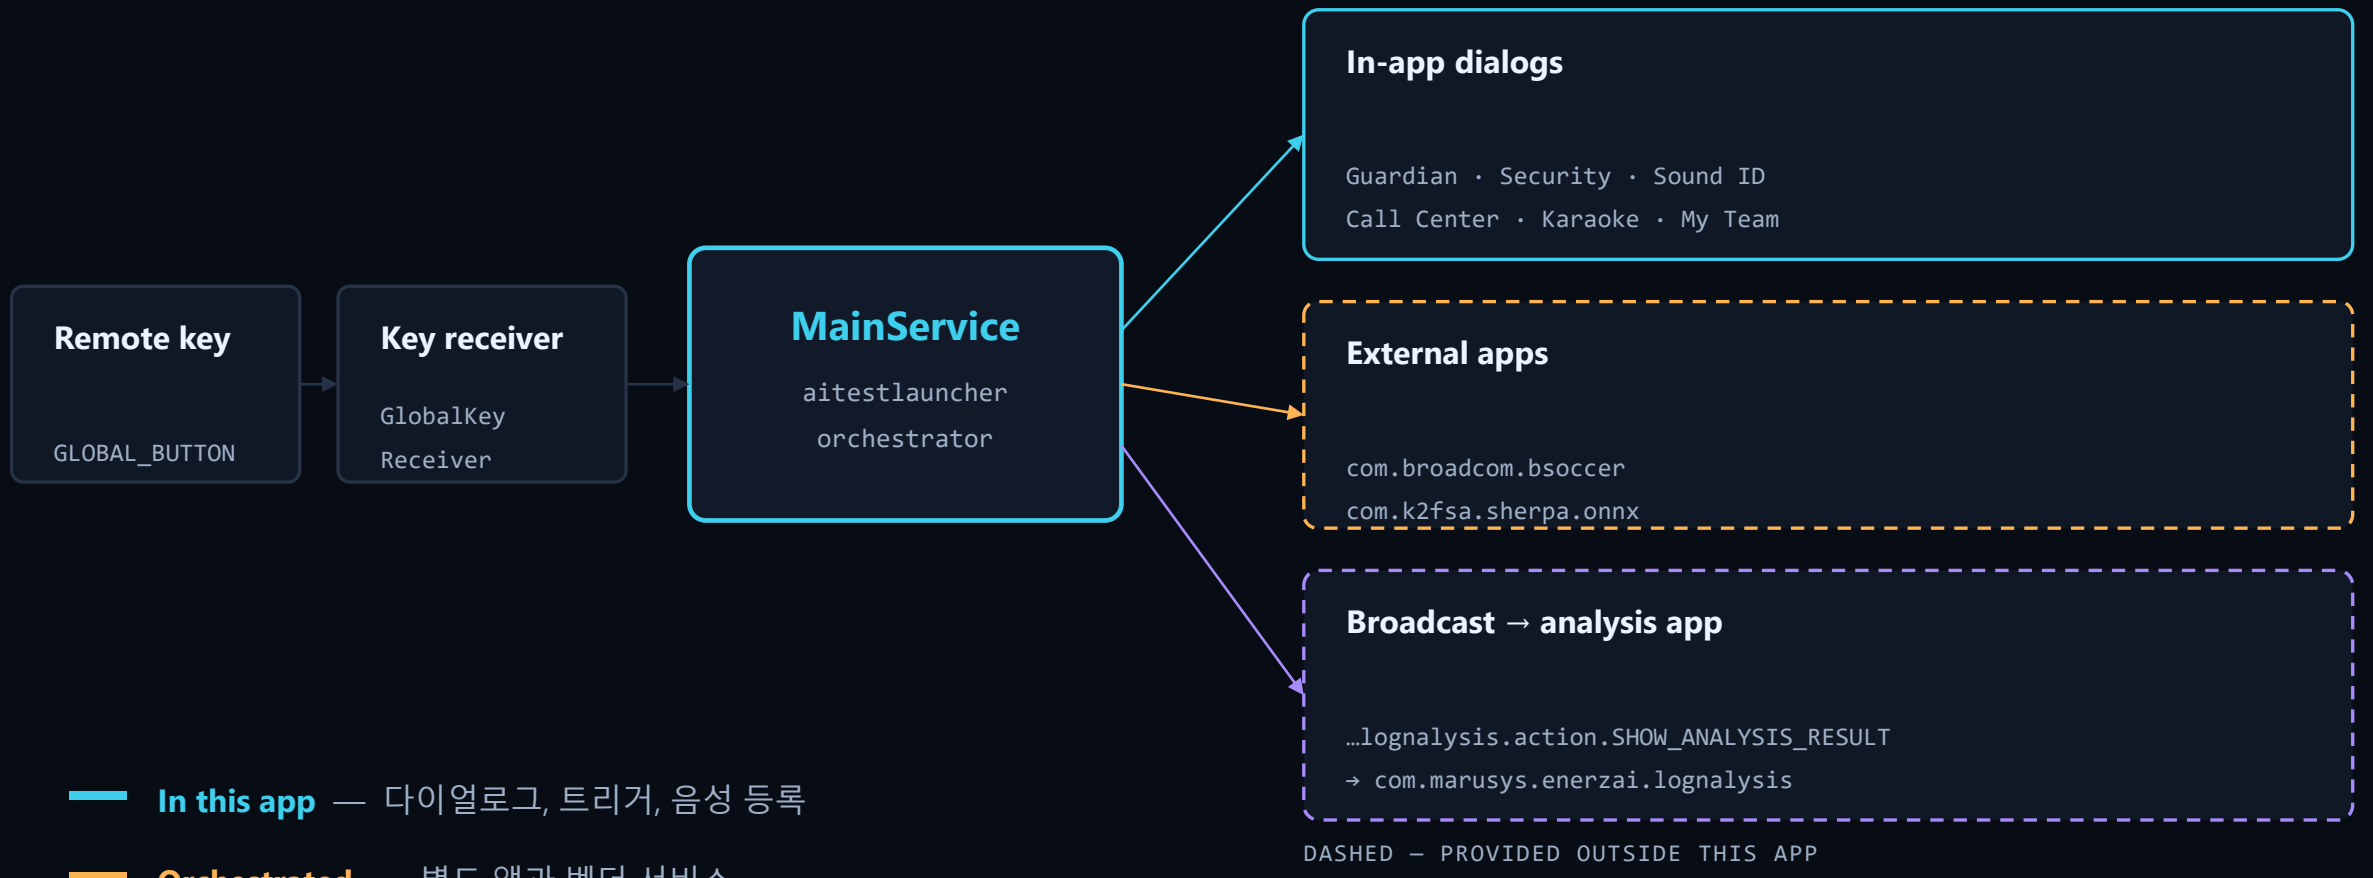
Marusys AI Suite

Nine AI features on one set-top box — sensing, voice identity, media and self-diagnosis.

01	Guardian — 공기·아이·반려동물
02	Security — 레이더 재실 감지
03	Call Center — 음성 지원
04	Sound ID — 화자 식별
05	My Team Event — 실시간 스포츠
06	Media AI — 화질·자막·노래방
07	System Health — 로그 분석

플랫폼	음성	분석	기능
Android TV 셋톱박스	**Sensory TrulySecure Voice**	**온디바이스 LLM**	**9**

One launcher, nine engines.



구조 보는 법

What we wrote, and what we route to.

In this app — 직접 구현

화면과 트리거, 그리고 Sound ID의 경우 모델까지 런처가 끝까지 책임집니다.

다이얼로그	Guardian · Security · Sound ID · Call Center · Karaoke · My Team
엔진	Sensory TrulySecure Voice — 호출어와 화자 인증
동작 위치	Call Center를 제외하면 모두 기기에서 돕니다. 그것만 질문을 OpenAI로 보냅니다.

Orchestrated — 불러 쓰는 것

런처가 실행하거나 켜주지만, 만들어지고 동작하는 곳은 별도 컴포넌트입니다.

앱	com.broadcom.bcameraman · com.broadcom.bsoccer · com.k2fsa.sherpa.onnx
서비스	벤더 QBS 오디오 · 온디바이스 LLM
동작 위치	전부 기기에서 — 인식도, 오디오 분리도, LLM도.

01 · 감지

Guardian

셋톱박스가 거실의 소리와 공기를 상시 살피고, 변화가 생기면 스스로 알립니다.

공기질	벤더 데몬이 미세먼지 센서를 읽고, 상태가 바뀌면 묻지 않아도 화면에 알림을 띄웁니다. 이 경로에는 모델이 없습니다.
아이 안전	울음을 감지하면 TV를 음소거하고 화면에 알림을 띄웁니다. TV 소리 때문에 못 듣는 상황을 그대로 겨냥한 기능입니다.
반려동물	이쪽은 휴대폰으로 갑니다. 셋톱박스가 디바이스 ID를 담아 알림을 보내면 페어링된 앱이 받고, 어느 요일 몇 시에 많이 짖는지까지 앱에 쌓입니다.
모델	**YAMNet** — AudioSet 체계의 MobileNet 계열 음향 이벤트 분류기. int8 TFLite 16 MB, 라벨 521개 중 `Baby cry, infant cry`와 `Bark`를 씁니다. 별도 앱 `com.broadcom.bcameraman`이 마이크를 받아 추론하고, 결과를 런처에 브로드캐스트로 넘깁니다.

3 가지

공기질, 아이 울음, 반려동물 짖는 소리.

AI 모델 · 온디바이스

YAMNet — 521 클래스 음향 이벤트 분류기. int8 TFLite, 기기에서 추론.

모델이 아닌 것

공기질은 센서 값이고 추론이 없습니다.

경로가 둘로 갈립니다

아이 울음은 TV에서 끝나고, 반려동물은 휴대폰으로 갑니다. 감지는 둘 다 기기에서 합니다.

02 · 재실 감지

Security

레이더 센서로 거실에 사람이 있는지, 몇 명인지를 셋톱박스가 파악합니다.

센서	카메라가 아니라 레이더입니다. 거실을 찍지 않고 재실 여부와 인원수만 읽습니다.
전원	사람이 모두 나가면 TV나 셋톱박스를 끄고, 돌아오면 다시 켜며 환영 메시지를 띄울 수 있습니다.
외출 모드	집을 비운 사이의 움직임을 침입 가능성으로 알립니다.

0 대

카메라 없이 재실 여부와 인원수만 읽습니다.

AI 모델 없음

레이더 센서 신호를 읽을 뿐, 이 경로에는 추론 단계가 없습니다.

03 · 음성

Call Center

셋톱박스의 문제를 셋톱박스에게 소리 내어 묻고, 해결 방법을 그대로 받습니다. 여기 아홉 개 중 기기 밖으로 나가는 유일한 기능입니다.

호출어	Sensory 트리거 모델 — 16 kHz 음향 모델을 `.trg` 파일로 담아 기기에서 실행합니다. 호출어 자체는 운영사별로 빌드합니다.
인식	Android `SpeechRecognizer` free-form 모드 — 온디바이스로 고정하지 않은 기본 인식기입니다.
답변	**OpenAI 모델**을 기기에서 HTTPS로 호출합니다.
근거	검색 단계가 없습니다. 약 1,000자 분량의 고정 지원 매뉴얼을 모든 질문 앞에 붙여, 그 범위 안에서만 답하도록 지시합니다.
왕복	질문과 답변이 모두 네트워크를 오갑니다. 연결이 필요한 것은 이 기능뿐이고, 나머지 여덟 개는 그렇지 않습니다.

1 개

아홉 개 중 유일하게 클라우드를 호출합니다.

AI 모델 · 클라우드

OpenAI 모델을 네트워크로 호출합니다. 기기에서 동작하는 것은 Sensory 트리거 모델뿐입니다.

트리거 모델

Sensory 3.15 포맷, 148 KB — 배경 모델, 남/여 각 6.9 KB, 호출 구절 모델 72 KB. log-mel 피처에 양자화 LSTM, 프레임마다 softmax를 내고 클래스 언어모델과 filler 모델로 디코딩합니다. 예/아니오 분류기가 아니라 키워드 스포팅입니다.

04 · 화자 식별

Sound ID

가족 구성원이 짧게 목소리를 등록하면, 그 뒤부터 셋톱박스가 누가 말하는지 구분합니다.

엔진	**Sensory TrulySecure Voice** (tssv 3.15.8) — 등록은 `TssvEnroller`, 인증은 `TssvAuthenticator`.
모델 구성	세 가지입니다. 16 kHz 음향 모델, 일반적인 화자를 대표하는 배경 모델(`sound-dependent-16kHz-iot.ubm`, 131 KB), 그리고 거기서 적응시켜 만드는 사람별 등록 모델.
등록	기본 4회 반복, 3~7회까지 설정할 수 있습니다. 데모 중 그 자리에 있는 사람들로 기기에서 모델을 만듭니다. 사람마다 미리 학습해 둔 것이 아닙니다.
활용	연령에 맞는 메뉴, 각자의 최근 시청 채널과 VOD, 그리고 세대가 아니라 말한 사람을 따라가는 추천.
이 앱 안에서	여기 기능 대부분과 달리 화자 인증은 런처 안에서 직접 동작합니다.

3 명

AI 모델 · 온디바이스

Sensory TrulySecure Voice. 화자 모델을 기기에서 만들고 기기에서 비교하며, 라이브러리는 NNAPI 경로도 쓸 수 있습니다.

모델 파일 안에는

배경 모델만 들어 있습니다 — 3.15 포맷, 131 KB. 엔진은 자체 TensorFlow Lite 빌드에 MFCC와 LSTM 커널을 담고 있고 NNAPI로도 실행할 수 있습니다.

05 · 실시간 이벤트

My Team Event

숫자 검출	**YOLOv4-tiny** — 416×416 int8 TFLite, 6.0 MB. 클래스를 `digit` 하나로 줄여 재학습했습니다. 1280×720 프레임을 416으로 줄여 넣으면 점수 숫자 박스를 돌려줍니다.
숫자 인식	**LeNet** — 72 KB int8 TFLite, 자체 숫자 데이터셋으로 재학습. 박스를 28×28 RGB로 잘라 0~9로 분류하고, 바뀌면 득점입니다.
알림 전달	득점을 잡으면 `com.marusys.aitestlauncher.SOCCER_GOAL` 을 보내고, 런처가 팝업과 채널 이동을 띄웁니다.
가속	두 모델 모두 네이티브 디텍터 하나가 들고 있고, 추론은 Broadcom TFLite delegate(`bstorm`)를 거칩니다.

1,600 프레임

경기 영상에서 직접 잘라 라벨링한 검출기 학습 셋입니다.

AI 모델 · 온디바이스 · 자체 학습

오픈소스에서 가져온 것은 구조뿐입니다. 가중치는 우리가 만든 데이터로 학습했습니다.

어떻게 학습시켰나

검출기는 darknet YOLOv4-tiny를 클래스 하나로 줄여 6,000 iteration, 3초 경기 클립에서 뽑은 약 1,600 프레임으로. 분류기는 폰트로 만든 숫자 데이터셋으로 from scratch 학습 후, 틀린 숫자 이미지를 더해 가며 반복했습니다.

06 · 미디어

Media AI

HQ VIDEO	Broadcom BrAIVE 화질 개선입니다. 디코더에 레벨 값으로 걸어 비디오 경로에서 처리하고 원본과 나란히 보여줍니다 — 멀리서 차이를 알아볼 수 있는 유일한 방법입니다.
실시간 자막	재생 중인 스트림을 실시간으로 받아 자막으로 올립니다. 방송이든 YouTube든 앱이든 동일합니다.
자막 모델	**Zipformer2** 스트리밍 트랜스듀서, sherpa-onnx 기반 — int8 encoder, float decoder, int8 joiner, 합계 77 MB. 한국어 유닛 사전 2,234개. greedy 디코딩으로 듣는 중에 단어를 내보내고, 1.4초 무음이면 문장을 끊습니다.
KARAOKE	재생 중인 오디오에서 보컬과 반주를 또 하나의 모델이 분리하고, 슬라이더로 균형을 맞춥니다.

3 가지

화질 개선, 실시간 자막, 보컬 분리.

AI 모델 · 온디바이스 · 두 개

음성 인식은 Zipformer2, 노래방은 벤더 음원 분리 네트워크입니다. HQ Video만 예외로, 가리킬 모델이 없는 파이프라인 기능입니다.

음원 분리 모델

벤더 MSS v1.3.0 — 약 460K 파라미터, 스테레오 48 kHz. conv와 transposed conv에 GRU와 sigmoid 마스크를 쓰고, 양자화해 ARM CMSIS-NN으로 프레임 단위로 스트리밍 추론합니다.

07 · 자가 진단

System Health

무엇을 읽나	부팅할 때마다 수집 서비스가 1분간 logcat을 모읍니다. 부팅 시간을 단계별로, 크래시·네트워크·저장공간까지 리포트에 담습니다.
무엇을 쓰나	크래시가 있으면 무슨 일이 있었는지 사람 말로 씁니다 — 지원팀용 진단과 고객용 조치, 두 문장입니다.
KV 캐시	문서마다 prefill을 미리 계산해 함께 넣었습니다 — 78개 파일, 약 675 MB. 실행할 때는 크래시 한 줄만 새로 계산합니다.
그 다음	문제가 잡히면 바로 그것을 고치는 화면으로 넘어갑니다 — 앱 삭제, 저장공간, 네트워크 설정.

600M 파라미터

sub-4bit 양자화, 가중치 128 MB. Optimium 엔진이 실행합니다.

AI 모델 · 온디바이스

600M LLM, 가중치 128 MB. 기기 안에서 Optimium 엔진이 실행합니다.

런처가 맡는 전부

System Health 메뉴가 분석 앱에 브로드캐스트 하나를 보냅니다.

어디서 도나

수집·상태 감지·결과 저장은 분석 앱이 맡고, 모델은 그 안에서 기기 위에서 실행됩니다.

플랫폼

What it runs on.

실리콘	
CPU	4코어 — Cortex-A55, 최대 2.85 GHz, ARMv8
GPU	Broadcom VideoCore VII (V3D-730), OpenGL ES 3.1
AI 실행	Broadcom `bstorm` 데몬이 HAL로 동작하며 TFLite delegate를 받칩니다.

시스템	
메모리	**4 GB** — 가용 3.62 GiB
저장소	data 파티션 20 GB
OS	Android 14 (API 34), Linux 커널 6.1.162
앱	com.marusys.aitestlauncher 1.01.19 — updated system app. 로그 분석은 com.marusys.enerzai.lognalysis 1.01.01 이며 system uid 로 동작합니다.

소스와 벤더 회신 기준

What it costs to run.

범위
9 개
셋톱박스 한 대에 담은 AI 기능

범위
8 개
그중 기기에서 동작합니다. Call Center만 OpenAI 호출

속도
8–14 tok/s
온디바이스 LLM 디코드 속도

메모리
600M 파라미터
온디바이스 LLM, sub-4bit 양자화

메모리
425 MB
LLM 런타임 피크 — weight와 KV cache 포함

범위
20 개
안드로이드에서 가장 흔한 Exception, 검색 코퍼스가 다룹니다

범위
8 개
기기에서 동작하는 모델 — 음향·호출어·화자·영상·음성·분리·언어

범위
0 회
로그 분석 경로에서 발생하는 클라우드 호출

Nine AI features, one set-top box.

감지, 화자 식별, 미디어 개선, 그리고 기기 자신의 로그를 읽는 모델까지 — 아홉 개 중 여덟 개가 기기 안에서 돌고, 전부를 런처 하나가 불러 씁니다.

측정 기준 · 보드에서 직접 읽은 값

CPU와 NPU — 같은 칩, 다른 일.

공개 스펙이 아니라 보드에서 직접 읽은 값으로 계산. 연산 성능만 비교하면 답이 반쪽이라, 실제 LLM이 어디에서 막히는지까지 함께 연구

CPU	SIMD	NPU	DRAM
Cortex-A76 ×1 @ 1.9 GHz · Cortex-A55 ×3 @ 1.7 GHz	asimddp — INT8 dot-product (SDOT)	3.5 TOPS	8 GB — 가용 7.27 GiB

TOPS = Tera Operations Per Second — 1초에 1조 번의 연산

출처 — /proc/cpuinfo · cpufreq · /dev/vipcore · /proc/meminfo

01 · 기준 잡기

1 TOPS는 CPU로 얼마나 되나?

클럭만으로는 환산되지 않습니다. 코어가 사이클당 몇 연산을 처리하는지를 고정해야 비로소 같은 단위로 비교할 수 있습니다.

TOPS란	**Tera Operations Per Second** — 1초에 1조 번의 연산
보드 CPU 전체	**4.9배** — 네 코어를 모두 100%로 돌렸을 때 기준
A76 코어	**8.2개** — 1.9 GHz, 사이클당 64 연산
A55 코어	**36.8개** — 1.7 GHz, 사이클당 16 연산
A76 클럭 환산	**15.6 GHz** — A76 한 코어로 환산했을 때
A55 클럭 환산	**62.5 GHz** — 같은 1 TOPS인데 4배 차이
스칼라 환산	**500 GHz** — SIMD를 쓰지 않으면

4.9 배

1 TOPS = 이 보드의 네 코어를 모두 100%로 돌린 것의 약 5배입니다.

환산식

연산량 = 클럭 × 사이클당 연산 수 × 코어 수. 이 셋을 모두 곱해야 TOPS가 됩니다. INT8에서는 곱셈·누산 한 쌍을 2 연산으로 셉니다.

왜 클럭만으로는 안 되나

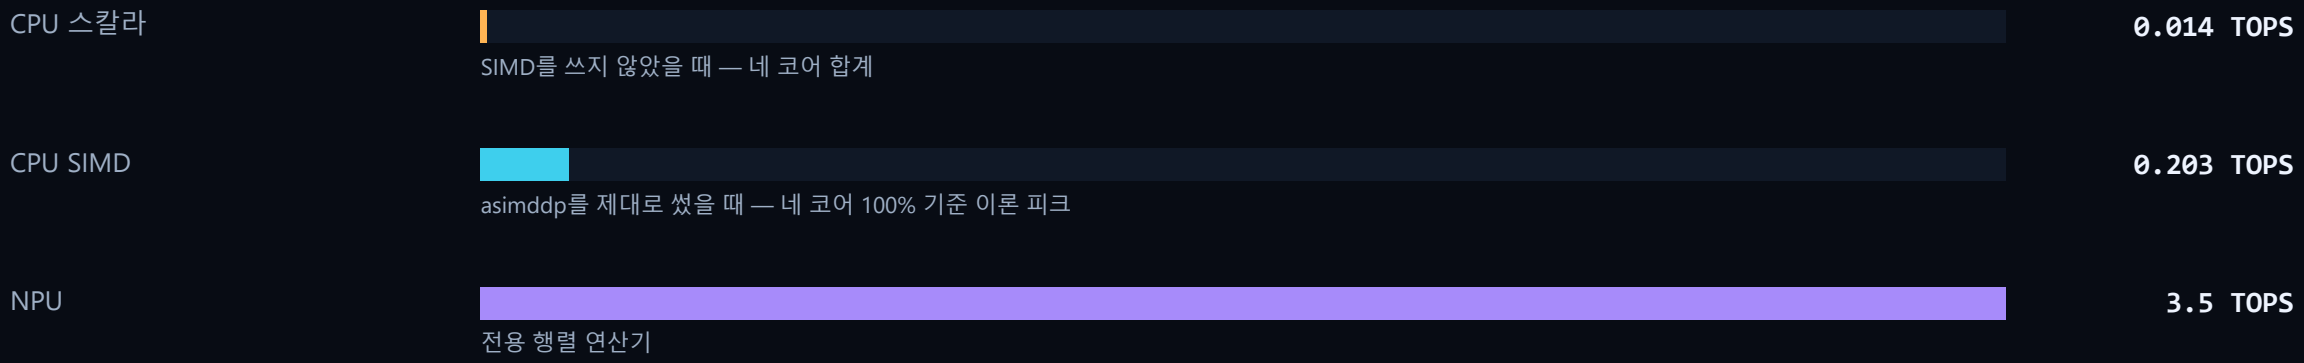
같은 1 TOPS가 A76 기준 15.6 GHz, A55 기준 62.5 GHz입니다. 클럭 숫자가 같아도 코어가 다르면 연산량이 다릅니다.

NPU 3.5 TOPS는 이 보드 CPU 전체의 17배, A76 코어 29개분입니다.

02 · INT8 피크 연산

연산량만 보면 17배입니다.

아래 CPU 수치는 네 코어를 모두 100%로 돌렸을 때의 이론 피크입니다. 실제로는 OS와 앱이 같은 코어를 쓰므로 이보다 낮습니다.



17×

SDOT를 제대로 쓴 CPU 대비 NPU의 배수입니다. SIMD 없이 스칼라만 쓰면 250배까지 벌어집니다 — 즉 이 배수는 CPU를 얼마나 잘 쓰느냐에 따라 달라집니다.

03 · 계산 근거

코어마다 SIMD 처리량이 다릅니다.

SDOT 한 번이 INT8 곱셈 16개, 즉 32 연산을 처리합니다. 코어가 사이클당 SDOT를 몇 개 내보내는지가 코어별로 다릅니다.

A76 ×1	128-bit SIMD 파이프 2개 — 사이클당 SDOT 2개. 1.9 GHz × 2 × 32 = **121.6 GOPS**
A55 ×3	SIMD가 2×64-bit라 128-bit SDOT에 2사이클. 1.7 GHz × 16 × 3코어 = **81.6 GOPS**
CPU 합계	네 코어를 모두 돌렸을 때의 이론 피크 = **203.2 GOPS = 0.203 TOPS**
NPU	전용 행렬 연산기 **3.5 TOPS** — 같은 INT8 기준

1.5 배

A76 한 개가 A55 세 개보다 빠릅니다. 코어 수가 성능 순서를 정하지 않습니다.

왜 그런가

A55는 SIMD 폭이 절반이라 같은 SDOT에 두 배의 사이클을 씁니다. 클럭 차이(1.9 대 1.7)보다 이 구조 차이가 훨씬 큽니다.

04 · 진짜 병목

토큰을 뽑을 때는 연산이 병목이 아닙니다.

토큰 하나마다 가중치 전체를 메모리에서 읽어야 합니다. 연산기가 아무리 빨라도 메모리가 공급하지 못하면 거기에서 멈춥니다.

11.5 GB/s

실효 메모리 대역폭

모델 1,270.8 MiB × 측정 디코드 8.57 tok/s → 약 11.5 GB/s.
같은 DRAM을 공유하는 한 CPU도 NPU도 이 선을 넘지 못합니다.

그래서 3.5 TOPS는 디코드 속도를 설명하지 못합니다. 이 프로젝트가 디코드를 5~6에서 8.57 tok/s로 올린 것도 연산을 늘려서가 아니라 DDR 대역폭 설정을 고쳐서였습니다.

05 · 정리

Prefill은 연산, Decode는 메모리.

NPU가 이득을 주는 구간과 그렇지 않은 구간이 나뉩니다. 3.5 TOPS는 앞쪽 구간의 지표입니다.

Prefill

첫 응답까지 — 행렬 연산량이 지배

TTFT −44%

NPU가 바로 이득인 구간입니다.

Decode

토큰 생성 — 메모리 대역폭이 지배

+8%

연산기를 바꿔도 크게 달라지지 않습니다.

제어 · I/O

분기와 비정형 연산

CPU

NPU가 맡을 수 없는 일이 남습니다.

한 줄로: 3.5 TOPS는 Prefill 지표입니다. 응답이 시작되기까지는 NPU가 줄이고, 그 뒤 말이 흘러나오는 속도는 메모리가 정합니다.

MARUSYS Products

Marusys Product Portfolio

Soft AP Hybrid STB

STB **145 x 122.5 x 38 mm**



- **SoC** : Amlogic S905X4
- **OS** : Android TV 11
- **Mem** : DDR4 3GB, eMMC 16GB
- **Wi-Fi** : Wi-Fi 6 802.11 ax (2T2R)
- **RJ-45** : WAN 1ea, LAN 1ea
- **BT** : Bluetooth 5.3

Marusys Product Portfolio

AI Set Top Box

STB **138 x 128 x 105 mm**



- **SoC** : Broadcom BCM 74116
- **OS** : Android TV 14
- **Mem** : DDR4 4GB, eMMC 32GB
- **Wi-Fi** : Wi-Fi 6 / 6E / 7
- **Speaker** : 20W (10W * 2ea), BT
- **BT** : Bluetooth 5.3

Marusys Product Portfolio

AI 4 Vision : FHD Camera

STB **175 x 85 x 39.7 mm**



- **SoC** : Synaptics VS680
- **OS** : Android TV 12
- **Mem** : LPDDR4 4GB, eMMC 32GB
- **Speaker** : 7W
- **BT** : Bluetooth 5.3

Marusys AI Solutions

NPU-Accelerated AI Services



AI-SR (Super Resolution)

AI-SR is NPU-based Image Enhancement to **convert low-resolution video into 4K-level high-resolution content, providing enhanced visual clarity and quality** regardless of the source

- **Enhanced Scalar**

Uses technology focused on making images sharper, thin & smooth with less noise and fewer artifacts. Improves low-resolution video to 4K-level quality and sharpness.

- **AI Superscalar**

Features high-speed processing without latency via an independent hardware (HW) block.



AI Subtitle

This system **extracts any audio stream being played on the STB** (including OTT content), processes it through On-device STT (Speech-to-Text), **and provides real-time translated subtitles.**

- **Whisper** : A non-cloud, on-device STT engine that provides high-accuracy processing without latency. (Heavy)
- **OpenAI Translator** : Utilizes verified translation engine supporting 14 different languages for high-quality multilingual output (Heavy)
- **Online Streaming Model** : A lightweight model optimized specifically for the Korean language, achieving a delay of under 2 seconds and an accuracy rate of 98% (Light)

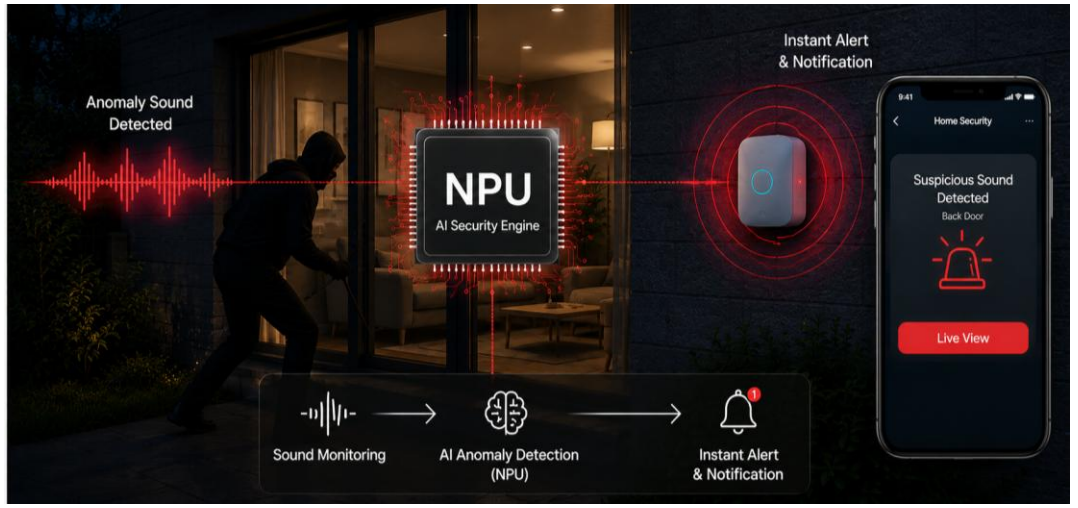
Marusys AI Solutions

AI Voice Optimization using Microphone



AI Volume Control Based on Ambient Noise

- The **built-in microphone continuously detects ambient noise levels** in the user's environment
- Based on real-time noise analysis, the **AI automatically adjusts the audio volume up or down** to maintain optimal speech clarity
- This adaptive volume control ensures consistent intelligibility of voice content even in dynamically changing noise conditions
- As a result, **users no longer need to manually adjust the volume with a remote**, significantly improving overall viewing convenience and experience



AI Home Security Based on Abnormal Noise Detection

This system **enhances home security by detecting abnormal noises inside house** and immediately sending emergency alerts to smartphone registered to STB

- **Abnormal Noise Sensing** : The device's microphone utilizes AI to distinguish between everyday household sounds and "abnormal" noises, such as glass breaking, crying, or forced entry
- **Real-time Alert System** : Once unusual sound is identified, STB automatically triggers a notification to the user's mobile, allowing for immediate action even when the user is away

Marusys Vietnam R&D Center

R&D Outsourcing Business

We specialize in developing a wide range of embedded systems and device solutions,
complemented by web and mobile services that seamlessly extend and enhance their functionality.

Android Device



- Android TV Device
- AOSP Custom Device

Web / Mobile Service



- Enterprise ERP / CRM
- Device Management
- Mobility Service

Android Automotive



- High-end Infotainment
- Vehicle Monitoring Platform

AI for Device



- Senior Care Robot + Emergency Control System
- AI Vision-based Parking Management System

About MARUSYS

Marusys at a Glance – Global IPTV & OTT Device Solution Provider

Marusys is globally recognized platform solution provider with nearly three decades of expertise in IPTV, OTT, and broadband technologies.

Company Snapshot

- Founded : Jan 9, 1998
- CEO : PARK YONG GYU
- Employees : HQ (100 people, R&D Engineers 70%)
  Vietnam (100 people, R&D Engineers 90%)
- Industry : IPTV / OTT / Broadband CPE / Robot
- Focus : STB, Broadband, Robot

Key Figures

- 28+ Years of Industry Leadership
- 1M+ Devices Supplied Annually
- Trusted supplier to Tier-1 Operators
  (KT, LGU+, SKB, JCOM, Viettel)
- Global R&D, QA and Engineering workforce
- Recognized partner of Google TV, Netflix (Self-Serve), and RDK ecosystem

Business Portfolio

- IPTV & OTT Devices
  Android TV / Google TV Operator Tier STB
  RDK-based STB / Hybrid IPTV & UHD PVR Solutions
- Broadband & Connectivity
  AP router / Soft AP & Embedded Network Devices
- AI & Emerging Solutions
  AI Speakers & Voice Control (FFV) / Smart Devices

Milestones

- 2020 : Freeview ATV PVR / KT All in One with Soft AP
- 2021 : KT first ATV box 'Genie TV A'
- 2022 : KT All in One 1 / KT Skylife All in One
- 2023 : Google Android TV Official Partnership / KT Genie 3VE
- 2024 : Netflix Self-serve Partner / KT ATV 8K STB 'Genie TV 4'
  SK Broadband AI 4 Vision
- 2025 : Google TV License / KCTV Jeju Broadcast ATV OTT STB
  LG U+ Wi-Fi STB / KT Skylife Genie A IPTV
  Entering Broadband Biz
- 2026 : Marusys Android TV Launcher / KT Giga Genie A2 STB

Global Presence

- Seoul HQ – Corporate Leadership & Core R&D
- Vietnam R&D Center (Hanoi) – Android TV, Broadband, Automotive & QA
- Japan & Europe Offices – Regional Sales & Technical Support
- Korea, Vietnam & China EMS Factories – Scalable Mass Production

Strategic Partners

Google TV
Powered by Android TV
RDK
NETFLIX
prime video
Disney+

Marusys Journey

2026
Marusys Android TV Launcher
KT Genie TV A2 based S905X5-J0D (Launch in August)

2025
Google TV License Google TV
LG U+ Wi-Fi Set Top Box based S905X5 LG U+
Entering Broadband Business
KT Skylife ATV STB (Genie A IPTV) based S905X4
KCTV Jeju Broadcasting ATV OTT STB (Netflix Self-serve) with X5M

2024
SK Broadband AI Speaker ATV (AI 4 Vision) with VS710 SK broadband
KT ATV 8K AI Speaker (Genie 4) with S928X
Netflix Self-serve Service Partner NETFLIX

2023
KT ATV AI Speaker (Genie 3VE) with S905X4
Google Android TV Official Partnership Google

2022
KT Skylife All in One with Soft AP based on RTD1319
KT All in One Box with Soft AP based S905X4

2021
KT first ATV box (Genie TV A) based on S905X4 kt androidtv

2020
Freeview ATV PVR based on BCM7278 Freeview
KT All in One with Soft AP TCC9010

2019
High-end 1st ATV Cable UHD based on BCM7268
Netflix OTT box based on S805

2017
Establishment of Vietnam R&D

2015
Market Entry into Vietnam's Satellite, UHD, Cable, and IP STB Operator

2010 ~2005
Establishment of Germany R&D Center
Commercial Deployment of Advanced DVB-S/S2, DVB-T, DVB-C, and Twin Tuner PVR STB Platforms Across Europe EU

2003
Provided solutions and implemented "Drum of the light" at the opening ceremony of Daegu Universiade Contest

2000
Venture Company Government Certification
Internet, TV, Set-top box OEM Export (Japan, Germany, Brazil)

1999
Marusys Research Laboratory Certification koita

1998
Founded

Marusys Main Clients Ecosystem Dashboard

Domestic Leader

SK broadband
LG U+
kt
kt skylife
KCTV
LG HelloVision
D'LIVE

MARKET STATUS
100% TOP-TIER COVERAGE

Overseas Footprint

Telefónica
orange
CANAL+
T
LIBERTY GLOBAL
J:COM
nuuday
VNVcab
NTT WEST
Ziggo
unitymedia
viettel
Freeview
DIGI RCS & RDS
fransat
TNT SAT LA TNT GRATUITE PAR LE SATELLITE

16+
GLOBAL GROUPS

2 Regions
EUROPE/ASIA

Marusys Technology Ecosystem Dashboard (Smart OTT Integration)

NETFLIX

- Strategic collaboration with Netflix for new OTT-integrated product development
- Recognized as Official Netflix Self-Serve Partner in Korea

OS Middleware Platforms

Powered by Android TV

RDK

Linux

Core Capability

Embedded OS Development

SoC Partners Cooperation

synaptics

amlogic

BROADCOM

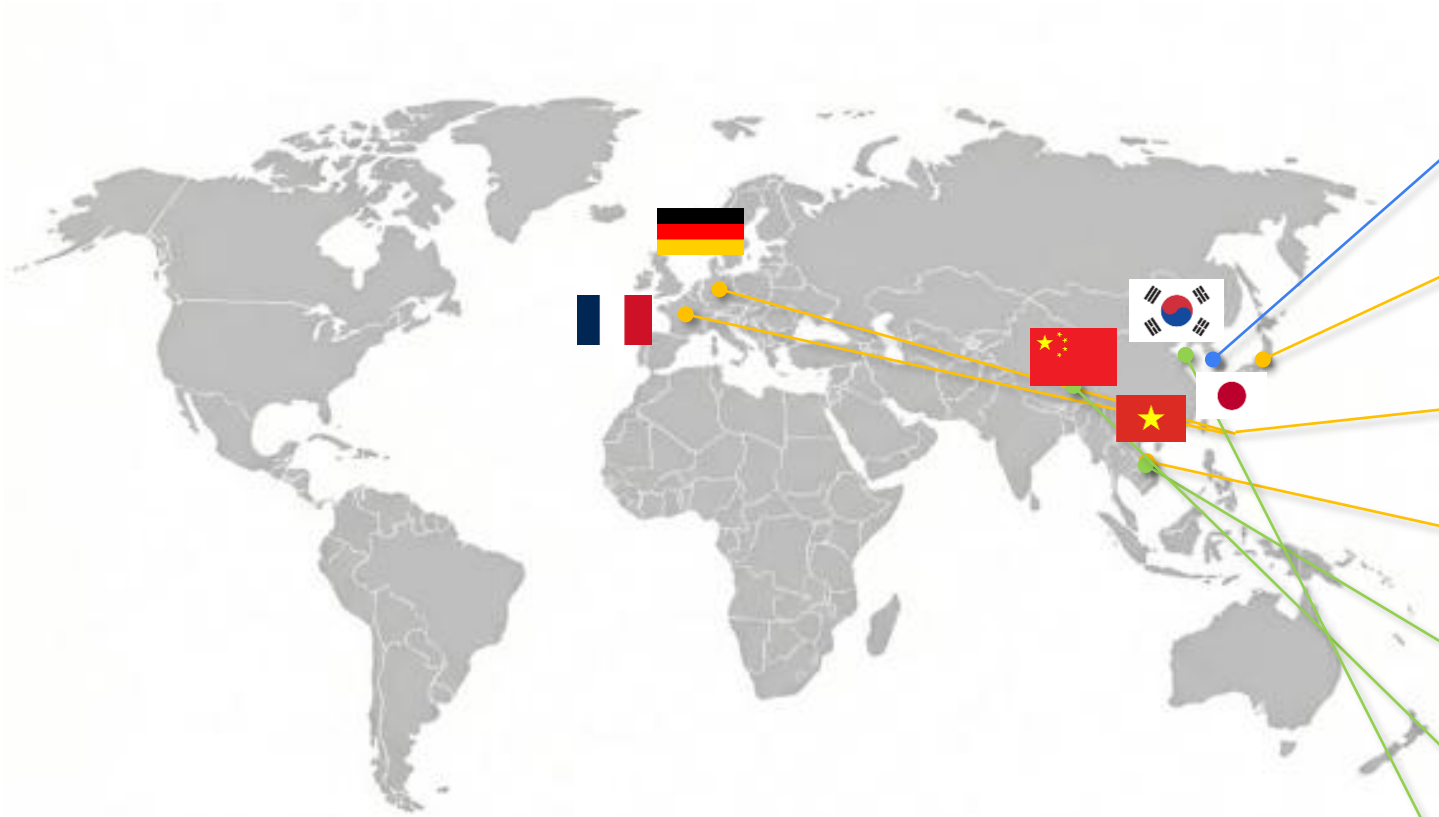
REALTEK

ALi

Strong Partnership

Leading Global SoC

Marusys Global Presence



Marusys Seoul HQ in South Korea

Tokyo Office
Sales Office, R&D, QA

Frankfurt, France Office
Sales Office, R&D, QA

Vietnam Office
R&D Office – STB, Broadband, Automotive, F/E & B/E, Mobile app

Hanoi EMS Factory
Production of ATV & AI Speakers

China EMS Factory
ATV model

Korea EMS Factory
ATV model

7
DIRECT GLOBAL SITES

3+
SALES OFFICES

3
R&D OFFICES

Marusys Product Roadmap (Set Top Box)

- AMLogic Product
- Synaptics Product
- Broadcom Product
- RealTek Product

IPTV + AI Speaker

OTT / IPTV

Smart AI Media

Ultra Low Power Consumption

2020 | 2021 | 2022 | 2023 | 2024 | 2025 | 2026



FreeView (UK)
- BCM 7278
- eMMC 16GB
- DDR4 3GB



SKB (KR)
- BCM 7268
- eMMC 8GB
- DDR4 2GB



J:Com (JP)
- BCM 7278
- eMMC 16GB
- DDR4 3GB



KT (KR)
- S905X4
- eMMC 16GB
- DDR4 3GB



KT (KR)
- S905X4
- eMMC 16GB
- DDR4 3GB



Skylife (KR)
- S905X4
- eMMC 16GB
- DDR4 3GB



KT (KR)
- S905X4
- eMMC 16GB
- LPDDR4 3GB



SKB (KR)
- VS710
- eMMC 32GB
- LPDDR4 4GB



KT (KR)
- S928
- 8K Display
- eMMC 32GB
- LPDDR4 6GB



Skylife (KR)
- S905X4
- eMMC 16GB
- LPDDR4 3GB



KCTV (KR)
- S905X4
- eMMC 16GB
- LPDDR4 3GB

TBA

KT (KR)
- S905X5
- eMMC 32GB
- LPDDR5 4GB

TBA

LGU+ (KR)
- S905X5
- eMMC 32GB
- LPDDR5 4GB



Global (EU)
- RTD1325
- eMMC 16GB
- LPDDR4 2GB

AI 셋톱박스 기반 Home AI Hub 전체 아키텍처

TV를 중심으로 가정의 모든 기기와 서비스를 연결하고, AI Agent가 생활을 이해하고 도와주는 홈 플랫폼

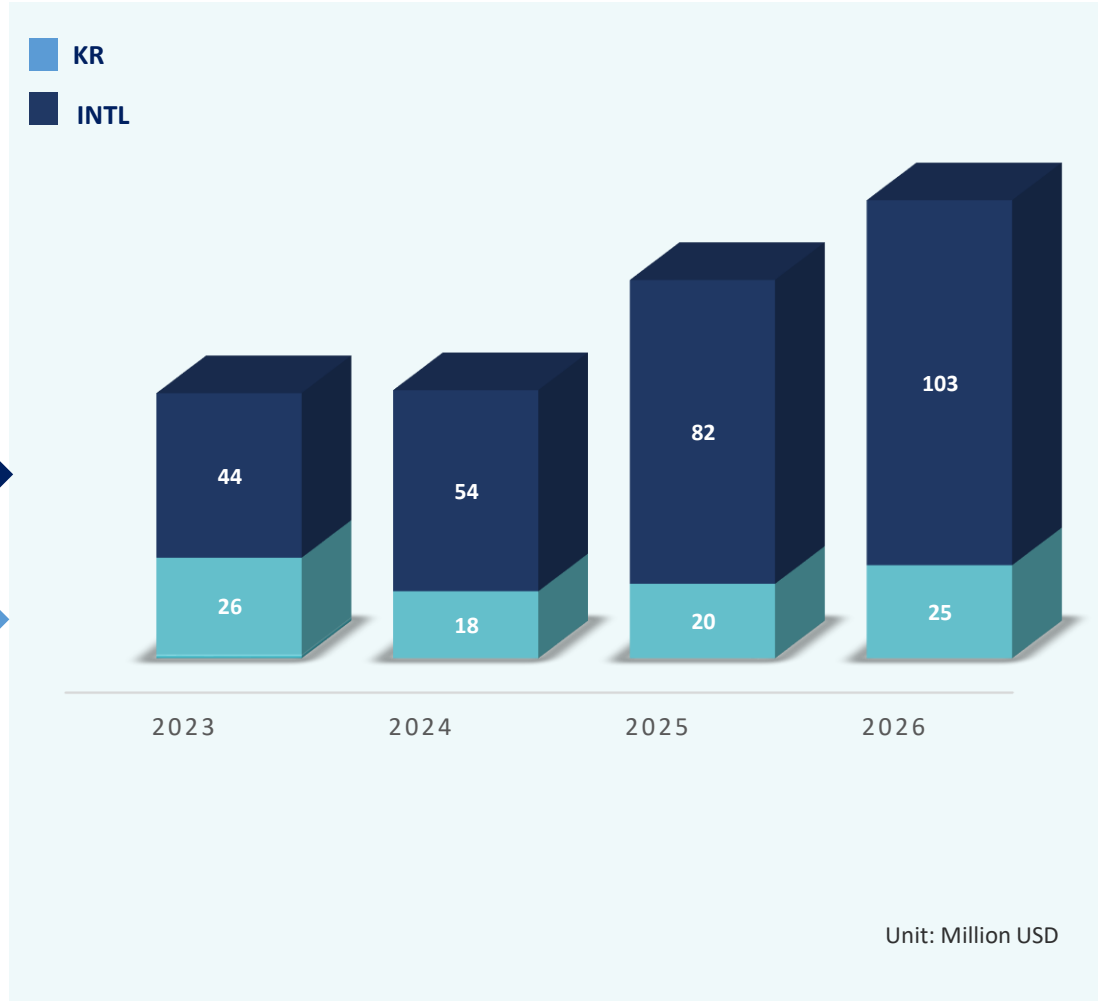


Marusys Sales Performance

Sales Revenue

Category	2023	2024	2025	2026(E)
Sales Revenue (KR)	44.2 Mil	54 Mil	81.6 Mil	103 Mil
Sales Revenue (INTL)	26 Mil	18 Mil	20 Mil	25 Mil

Unit: USD



Unit: Million USD

LIFE





오로라를 본다는 것은 아주 황홀하고 신비로운 경험임에 틀림이 없으나, 이를 보려면 추운 날씨, 오랜 기다림, 빛이 없는 장소를 찾아가야 하는 정성 등 - 오로라를 보기 위한 - 대가를 치루어야만 합니다.

그런 면에서 오로라를 보려고 하는 시도는 우리가 살아가는 인생과 많이 닮아 있습니다.

많은 사람이 보고 싶어 하지만, 쉽게 볼 수 없는
쉽게 보려고 하지만, 필요한 대가를 치러야 하는...

오로라를 맨눈으로 보는 것은 매우 드문 일입니다. 보통은 하늘에 구름이 있는데 조금 다른 형태의 모습이며 이를 핸드폰이나 카메라로 보면 선명한 녹색이 나타나는 경우가 많습니다.

아주 가끔 맨눈으로 보는 행운이 주어지기도 하는데, 이는 일 년에 며칠 없고, 오로라 지수 4이상일 경우에 맨눈으로도 녹색이 보이며 더 아름다운 주황빛과 노란빛 오로라를 보는 경우도 있습니다. 이 경우에도 카메라를 통해서 보면 더 황홀합니다.

12 December
Northern Lights (Aurora)

THANK YOU

감사합니다